

Curso: Aprendizagem de Máquina em Inteligência Artificial

Disciplina: Aprendizado Não Supervisionado

Prof. Marcelo Novaes de Rezende



PCA

Principal Component Analysis (PCA)



Faculdade de Computação e Informática
Mackenzie

Antes, vamos ver a base
matemática de PCA
Autovalores e Autovetores



Faculdade de Computação e Informática
Mackenzie

Autovalores e Autovetores

Seja M uma matriz, v um vetor e λ um escalar.

Dizemos que v é um autovetor de M e λ é seu autovalor associado quando:

$$Mv = \lambda v$$

Assim, a transformação linear causada por M em um vetor é equivalente ao produto de um escalar por esse vetor...vamos destacar alguns pontos:

- 1) o produto de um escalar λ (>0) por um vetor gera outro vetor paralelo ao inicial. Por exemplo, o vetor $(x,y)=(0,4)$ está em y . Se o multiplicarmos por 2, será $(0,8)$, ainda no eixo y .
- 2) Devemos sempre pensar em pares (autovalor, autovetor)
- 3) A matriz M é quadrada
- 4) Autovalores podem ser números reais ou imaginários



Faculdade de Computação e Informática
Mackenzie

Autovalores e Autovetores

Pergunta:

O vetor $v=(0.707,0.707)$ é um autovetor da matriz

$$M = \begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix} \quad ?$$



4 é o autovalor associado?

Em Python, vamos ver `pca1.ipynb`

$$\begin{aligned} \textcircled{A} \quad & \overbrace{\begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix} * \begin{bmatrix} 0.707 \\ 0.707 \end{bmatrix}}^{Mv} = \begin{bmatrix} 1 \cdot 0.707 + 3 \cdot 0.707 \\ 3 \cdot 0.707 + 1 \cdot 0.707 \end{bmatrix} = \begin{bmatrix} 2.82 \\ 2.82 \end{bmatrix} \\ \textcircled{B} \quad & \underbrace{4 * \begin{bmatrix} 0.707 \\ 0.707 \end{bmatrix}}_{\lambda v} = \begin{bmatrix} 2.82 \\ 2.82 \end{bmatrix} \\ & \text{Portanto } A=B \Rightarrow \text{SIM!} \end{aligned}$$



Faculdade de Computação e Informática
Mackenzie

Autovalores e Autovetores

O vetor $v=(0.707,0.707)$ é um autovetor da matriz

$$M = \begin{pmatrix} 1 & 3 \\ 3 & 1 \end{pmatrix}$$

Vamos aplicar a transformação da matriz a pontos de um “grid” 10x10..e observar o resultado...em Python.



Faculdade de Computação e Informática
Mackenzie

Autovalores e Autovetores...como obtê-los?

$$Mv = \lambda v$$

$$(M - \lambda I)v = 0 \quad (1)$$

Obs: I é a matriz identidade..

Obs: 0 é um vetor de “ m ” zeros.

Obs: λ é um escalar (número)

Obs: M é uma matriz quadrada $m \times m$

Obs: $M - \lambda I$ é uma matriz quadrada $m \times m$

Obs: v é um vetor com m componentes

Essa equação **1** (sistema de equações lineares homogêneo) tem uma solução trivial por ser um produto com resultado um vetor zero (vetor $v=0$). Para que existam outras soluções além da trivial, o determinante de $M - \lambda I$ deve ser nulo. Dessa imposição, chegamos em uma equação que nos permite encontrar os autovalores e, depois, os autovetores (obviamente).



Faculdade de Computação e Informática
Mackenzie

Autovalores e Autovetores

$$M = \begin{bmatrix} 1 & -2 \\ 3 & 9 \end{bmatrix}, \quad Mv = \lambda v, \quad \underbrace{(M - \lambda I)}_I v = 0$$

Impon $\det[M - \lambda I] = 0$ para que a equação I tenha mais que uma solução:

$$M - \lambda I = \begin{bmatrix} 1 & -2 \\ 3 & 9 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1-\lambda & -2 \\ 3 & 9-\lambda \end{bmatrix}$$

$$\det \begin{bmatrix} 1-\lambda & -2 \\ 3 & 9-\lambda \end{bmatrix} = (1-\lambda)(9-\lambda) - (-2 \times 3)$$

$$\det = 9 - \lambda - 9\lambda + \lambda^2 + 6 = 0$$

$$\lambda^2 - 10\lambda + 15 = 0 \Rightarrow \lambda_1 \approx 8.16$$

$$\lambda_2 \approx 1.84$$

Solução da equação
de 2º grau!

Exemplo: Obter os
autovalores de

$$M = \begin{vmatrix} 1 & -2 \\ 3 & 9 \end{vmatrix}$$

No Python,
pca2.ipynb



Faculdade de Computação e Informática
Mackenzie

Autovalores e Autovetores

Para $\lambda=8.16$, o autovetor correspondente é :

$$(M - \lambda I)v = 0$$

$$\begin{pmatrix} -7.16 & -2 \\ 3 & 0.84 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$-7.16x - 2y = 0$$

Exemplo: para $x=1$ $v = \{1, -3.58\}$ Obs: há infinitos autovetores paralelos ao primeiro....

$$\text{Teste: } \begin{pmatrix} 1 & -2 \\ 3 & 9 \end{pmatrix} \begin{pmatrix} 1 \\ -3.58 \end{pmatrix} = 8.16 \begin{pmatrix} 1 \\ -3.58 \end{pmatrix} \quad ? \text{ Vamos ao Python ([pca2.ipynb](#))}$$



Faculdade de Computação e Informática
Mackenzie

Autovalores e Autovetores

Analogamente, para $\lambda=1.84$, o autovetor correspondente é :

$$(M - \lambda I)v = 0$$

$$\begin{pmatrix} -0.84 & -2 \\ 3 & 7.16 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{aligned} -0.84x - 2y &= 0 \\ y &= -0.42x \end{aligned}$$

Exemplo: para $x=1$ $v = \{1, -0.42\}$

$$\text{Teste: } \begin{pmatrix} 1 & -2 \\ 3 & 9 \end{pmatrix} \begin{pmatrix} 1 \\ -0.42 \end{pmatrix} = 1.84 \begin{pmatrix} 1 \\ -0.42 \end{pmatrix} \quad ? \text{ Sim! Vamos ao Python ([pca2.ipynb](#))}$$



Faculdade de Computação e Informática
Mackenzie

Autovalores e Autovetores

É interessante deixar os autovetores com módulo 1. Para isso, basta obter a norma e dividir seus componentes por essa norma...

$\lambda=8.16$ o vetor $v=\{1, -3.58\}$ tem norma: 3.72
e fica $v=\{0.27, -0.96\}$ com norma 1

$\lambda=1.84$ o vetor $v=\{1, -0.42\}$ tem norma: 1.08
e fica $v=\{0.92, -0.39\}$ com norma 1



Faculdade de Computação e Informática
Mackenzie

Autovalores e Autovetores

Propriedade Importante:

O produto dos autovalores é o determinante da matriz:

$$M = \begin{pmatrix} 1 & -2 \\ 3 & 9 \end{pmatrix} \quad \det(M) = 9 + 6 = 15 = 8.16 * 1.84$$

Vamos testar tudo isso no Python! [`pca3.ipynb`](#)



Faculdade de Computação e Informática
Mackenzie

Correlação Pearson e Spearman
Vamos analisar os notebooks

Correlations*.ipynb



Faculdade de Computação e Informática
Mackenzie

Hermitian Matrix

A matriz M é 'Hermitiana' se a transposta da conjugada é a própria M (?)

Exemplos:

$$\begin{bmatrix} 3 & 2+i & -i \\ 2-i & 5 & 5-i \\ i & 5+i & -1 \end{bmatrix} \quad \begin{bmatrix} 0 & 2 & -i & 10+i \\ 2 & 1 & 0 & -5i \\ i & 0 & -2 & 0 \\ 10-i & 5i & 0 & 5 \end{bmatrix} \quad \begin{bmatrix} 0 & i & i \\ -i & 0 & i \\ -i & -i & 0 \end{bmatrix}$$

É fácil identificá-las: Na diagonal principal só há reais e os elementos simétricos são conjugados ($a+bi$, $a-bi$)

Toda matriz real simétrica é Hermitiana.

Toda Matriz hermitiana tem autovalores reais

Os autovetores associados a autovalores diferentes são ortogonais



Faculdade de Computação e Informática
Mackenzie

Matriz de Covariância

Covariância:

$$\sigma(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Matriz de covariância
(para 3 features)

$$\begin{bmatrix} \text{Var}_1 & \text{Cov}_{1,2} & \text{Cov}_{1,3} \\ \text{Cov}_{1,2} & \text{Var}_2 & \text{Cov}_{2,3} \\ \text{Cov}_{1,3} & \text{Cov}_{2,3} & \text{Var}_3 \end{bmatrix}$$

Matrizes de Covariância são reais e simétricas,
portanto Hermitianas

Todas as matrizes de covariância são positivas semi definidas.
Isso implica que todos os autovalores são positivos.

Uma matriz positiva semi definida $A \Rightarrow v_t A v_t \geq 0$ para qualquer v diferente de zero

Vamos ver em Python `pca4.ipynb`



Faculdade de Computação e Informática
Mackenzie

PCA : Principal Component Analysis

A Análise de Componentes Principais (PCA) é um ferramenta de redução de dimensionalidade que pode ser usada para reduzir um grande conjunto de variáveis para um pequeno conjunto que ainda contém a maioria das informações do conjunto grande



Faculdade de Computação e Informática
Mackenzie

PCA : Principal Component Analysis

Basicamente, partimos da matriz de covariância entre as features e extraímos seus autovalores e autovetores correspondentes.

Os autovetores associados a maiores autovalores indicam maior “variância naquele eixo” => mais importância...mais variância, mais informação

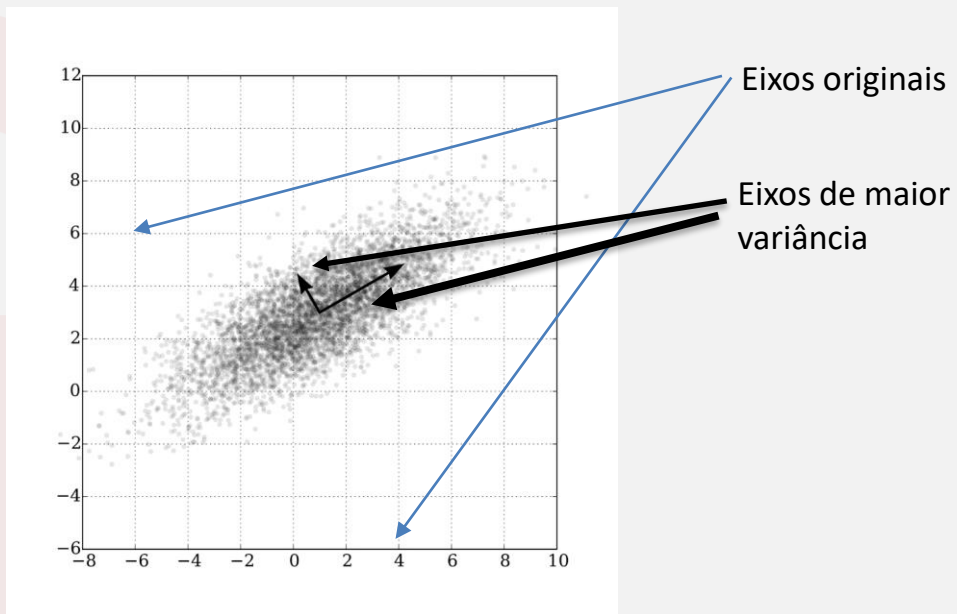
Podemos representar o dataset nesses eixos dos autovetores com menos dimensões que o inicial desprezando os eixos com autovalores baixos.

É possível voltar ao dataset inicial, mas com perdas....



Faculdade de Computação e Informática
Mackenzie

PCA : Principal Component Analysis



Faculdade de Computação e Informática
Mackenzie

PCA : Principal Component Analysis

Partindo de `pca5.ipynb`

- 1) Analisar o código com scikit
- 2) Verificar a matriz de covariância antes e depois das transformações
- 3) Calcular a acurácia (logistic regression) para classificação multiclasse (3) só com dois componentes (após PCA) e com 4 componentes (Original)
- 4) Reconstruir o dataset (de 2 para 4 features) e observar perdas (é uma lossy compression)
- 5) Fazer a visualização 2D das 3 classes após PCA

Usar `pca5.ipynb`



Faculdade de Computação e Informática
Mackenzie

PCA: Partindo de `pca6.ipynb`, e sem standardizar as features, veja o mínimo de features necessárias (Obtidas por PCA) para se ter mais de 80% de acurácia com regressão logística na classificação de fraude ou não.



Faculdade de Computação e Informática
Mackenzie

Até a próxima aula

OBRIGADO!

Prof Marcelo Rezende
email rezendemn@gmail.com