

Atividade MNIST-RandomForest

December 8, 2020

1 Lendo dados do MNIST

```
[1]: from sklearn.datasets import fetch_openml
mnist = fetch_openml('mnist_784', version=1)
mnist.keys()
```

```
[1]: dict_keys(['data', 'target', 'frame', 'categories', 'feature_names',
'target_names', 'DESCR', 'details', 'url'])
```

```
[2]: 28*28
```

```
[2]: 784
```

2 Conjunto de dados

```
[4]: X, y = mnist["data"], mnist["target"]
X.shape, y.shape
```

```
[4]: ((70000, 784), (70000,))
```

3 Observando um caractere do MNIST

```
[5]: import matplotlib as mpl
import matplotlib.pyplot as plt

some_digit = X[0]
some_digit_image = some_digit.reshape(28, 28)

plt.imshow(some_digit_image, cmap = mpl.cm.binary, interpolation="nearest")
plt.axis("off")
plt.show()
```



```
[6]: some_digit
```

[illegible]

0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	14.,	1.,	154.,	253.,	90.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
139.,	253.,	190.,	2.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	11.,	190.,	253.,	70.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	35.,	241.,	225.,	160.,	108.,	1.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	81.,	240.,
253.,	253.,	119.,	25.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	45.,	186.,	253.,	253.,	150.,	27.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	16.,	93.,	252.,	253.,	187.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	249.,	253.,
249.,	64.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	46.,	130.,	183.,	253.,	253.,	207.,	2.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	39.,	148.,	229.,	253.,	253.,	253.,
250.,	182.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	24.,	114.,
221.,	253.,	253.,	253.,	253.,	201.,	78.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	23.,	66.,	213.,	253.,	253.,	253.,	253.,	198.,	81.,
2.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	18.,	171.,	219.,	253.,	253.,
253.,	253.,	195.,	80.,	9.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	55.,
172.,	226.,	253.,	253.,	253.,	253.,	244.,	133.,	11.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	136.,	253.,	253.,	253.,	212.,	135.,
132.,	16.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,	0.,
0.,	0.,	0.]								

```
[7]: X[1].reshape(28, 28)
```

```
[7]: array([[ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0.,  0.,  51., 159., 253., 159., 50.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0.,  0., 48., 238., 252., 252., 252., 237.,  0.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           0.,  0., 54., 227., 253., 252., 239., 233., 252., 57.,  6.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           10., 60., 224., 252., 253., 252., 202., 84., 252., 253., 122.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
           163., 252., 252., 252., 253., 252., 252., 96., 189., 253., 167.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  51.,
           238., 253., 253., 190., 114., 253., 228., 47., 79., 255., 168.,
           0.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0., 48., 238.,
           252., 252., 179., 12., 75., 121., 21.,  0.,  0., 253., 243.,
           50.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0., 38., 165., 253.,
           233., 208., 84.,  0.,  0.,  0.,  0.,  0.,  0., 253., 252.,
           165.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0., 7., 178., 252., 240.,
           71., 19., 28.,  0.,  0.,  0.,  0.,  0.,  0., 253., 252.,
           195.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0., 57., 252., 252., 63.,
           0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0., 253., 252.,
           195.,  0.,  0.,  0.,  0.,  0.],
          [ 0.,  0.,  0.,  0.,  0.,  0.,  0., 198., 253., 190.,  0.,
           0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0., 255., 253.,
           196.,  0.,  0.,  0.,  0.,  0.]])
```

```
[ 0.,  0.,  0.,  0.,  0.,  0., 76., 246., 252., 112.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0., 253., 252.,
148.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0., 85., 252., 230., 25.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.,  7., 135., 253., 186.,
12.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0., 85., 252., 223.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  7., 131., 252., 225., 71.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0., 85., 252., 145.,  0.,  0.,
  0.,  0.,  0.,  0.,  0., 48., 165., 252., 173.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0., 86., 253., 225.,  0.,  0.,
  0.,  0.,  0.,  0., 114., 238., 253., 162.,  0.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0., 85., 252., 249., 146., 48.,
29., 85., 178., 225., 253., 223., 167., 56.,  0.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0., 85., 252., 252., 252., 229.,
215., 252., 252., 252., 196., 130.,  0.,  0.,  0.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0., 28., 199., 252., 252., 253.,
252., 252., 233., 145.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0.,  0., 25., 128., 252., 253.,
252., 141., 37.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.],
[ 0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,  0.,
  0.,  0.,  0.,  0.,  0.,  0.,  0.]])
```

4 Divida o dataset entre conjunto de treinamento e teste

Utilize 33% para o conjunto de teste

```
[43]: from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.33)
```

5 Construa uma random forest e verifique a acurácia do modelo.

Utilize o algoritmos tradicional do sklearn

```
[44]: from sklearn.ensemble import RandomForestClassifier
```

```
[45]: randForest = RandomForestClassifier(n_estimators=100)
      randForest.fit(X_train, y_train)
```

```
[45]: RandomForestClassifier()
```

```
[46]: y_pred = randForest.predict(X_test)
```

```
[47]: from sklearn import metrics
```

```
[48]: acc_rf = metrics.accuracy_score(y_test, y_pred)
      print("Acurácia = ", acc_rf)
```

Acurácia = 0.9659740259740259

```
[49]: acc_list = []
      acc_list.append(acc_rf)
```

6 Construa uma random forest a partir dos métodos de bagging e pasting e compare a acurácia do modelo

```
[50]: from sklearn.ensemble import BaggingClassifier
      from sklearn.tree import DecisionTreeClassifier
```

```
[51]: bag_clas = BaggingClassifier(
      DecisionTreeClassifier(random_state=42), n_estimators=100,
      max_samples=100, bootstrap=True, n_jobs=-1, random_state=42)
      bag_clas.fit(X_train, y_train)
```

```
[51]: BaggingClassifier(base_estimator=DecisionTreeClassifier(random_state=42),
      max_samples=100, n_estimators=100, n_jobs=-1,
      random_state=42)
```

```
[52]: y_pred = bag_clas.predict(X_test)
```

```
[53]: acc_list.append(metrics.accuracy_score(y_test, y_pred))
```

```
[54]: pasting_clas = BaggingClassifier(
      DecisionTreeClassifier(random_state=42), n_estimators=100,
      max_samples=100, bootstrap=False, n_jobs=-1, random_state=42)
      pasting_clas.fit(X_train, y_train)
```

```
[54]: BaggingClassifier(base_estimator=DecisionTreeClassifier(random_state=42),
                        bootstrap=False, max_samples=100, n_estimators=100, n_jobs=-1,
                        random_state=42)
```

```
[55]: y_pred = pasting_clas.predict(X_test)
```

```
[56]: acc_list.append(metrics.accuracy_score(y_test, y_pred))
```

```
[57]: print("Random Forest:", acc_list[0])
      print("Bagging:", acc_list[1])
      print("Pasting:", acc_list[2])
```

Random Forest: 0.9659740259740259

Bagging: 0.8311688311688312

Pasting: 0.8301731601731601

7 Desafio

Altere os hyperparameters do modelo de random forest e verifique qual modelo apresenta melhor acurácia. Assim como se você tivesse que apresentar esses resultados para o ser cliente.

Teste os diferentes métodos de ensemble mostrados na disciplina.

- Bagging
- Pasting
- Boosting
- ...

```
[58]: from sklearn.ensemble import AdaBoostClassifier

ada_clf = AdaBoostClassifier(
    DecisionTreeClassifier(max_depth=1), n_estimators=100,
    algorithm="SAMME.R", learning_rate=0.5, random_state=42)
ada_clf.fit(X_train, y_train)
```

```
[58]: AdaBoostClassifier(base_estimator=DecisionTreeClassifier(max_depth=1),
                        learning_rate=0.5, n_estimators=100, random_state=42)
```

```
[59]: y_pred = ada_clf.predict(X_test)
      metrics.accuracy_score(y_test, y_pred)
```

```
[59]: 0.7967099567099567
```

```
[62]: from sklearn.ensemble import GradientBoostingRegressor

gbrt = GradientBoostingRegressor(max_depth=2, n_estimators=3,
                                learning_rate=1.0, random_state=42)
gbrt.fit(X_train, y_train)
```

```
[62]: GradientBoostingRegressor(learning_rate=1.0, max_depth=2, n_estimators=3,  
                                random_state=42)
```

```
[66]: gbrt.score(X_test, y_test)
```

```
[66]: 0.4347195636119532
```